Detección de ciberataques en la red C-Town (BATADAL)

Metodología y fundamentos teóricos del modelo VGAE + SPC

Resumen

Se propone un detector de ciberataques para el sistema de distribución de agua C-Town que combina un *Variational Graph Autoencoder* (VGAE) con cartas de Control Estadístico de Procesos (SPC). Los sensores del sistema SCADA se representan como nodos de un grafo construido a partir de la topología hidráulica y de la lógica de control de la red. El VGAE se entrena únicamente con operación normal y aprende a reconstruir ventanas temporales de cada sensor; durante la operación, el error de reconstrucción se vigila con una carta EWMA sobre un estadístico estandarizado por sensor y con la carta SPE, y el espacio latente con el T^2 de Hotelling. Los hiperparámetros del modelo y de la carta se seleccionan con optimización bayesiana (TPE) sobre un conjunto de validación con ataques, y la evaluación final se realiza sobre el conjunto de prueba de BATADAL sin reajuste.

Índice

1 Planteamiento del problema **2**

2 Datos **2**
2.1 Conjuntos de BATADAL 2
2.2 Variables y preprocesamiento 2
2.3 Ventanas deslizantes 3

3 Grafo de sensores **3**
3.1 Motivación 3
3.2 Construcción 3

4 Fundamentos teóricos del modelo **4**
4.1 Redes convolucionales sobre grafos 4
4.2 Autoencoder variacional 4
4.3 Variational Graph Autoencoder 5
4.4 Adaptación al monitoreo de sensores 5
4.5 Variante con convolución temporal 6
4.6 Función de pérdida 7
4.7 Por qué el error de reconstrucción detecta ataques 7

5 Control estadístico de procesos sobre las salidas del VGAE **7**
5.1 Criterios para elegir las cartas 7
5.2 Estadístico por sensor 8
5.3 Límites de control empíricos 8
5.4 Carta EWMA sobre el residuo 9
5.5 Carta T^2 de Hotelling sobre el espacio latente 9
5.6 Carta SPE (estadístico Q) 9
5.7 Regla combinada 9

6 Métrica de evaluación **9**

7 Protocolo experimental **10**
7.1 Entrenamiento 10
7.2 Optimización de hiperparámetros 10
7.3 Comparación de cartas 11
7.4 Evaluación de la convolución temporal 11
7.5 Diagnóstico 12
7.6 Resumen del procedimiento 12

1 Planteamiento del problema

Sea $\mathbf{x}_t \in \mathbb{R}^N$ el vector de lecturas SCADA en la hora t. El objetivo es construir una regla $\hat{y}_t \in \{0, 1\}$ que indique si en el instante t el sistema está bajo ataque, usando solo información disponible hasta t. El problema se aborda como *detección de anomalías semisupervisada*: el modelo aprende la distribución de la operación normal y se declara una alarma cuando las observaciones se apartan de ella de forma estadísticamente significativa. Los datos etiquetados con ataques se usan exclusivamente para elegir hiperparámetros y para evaluar.

Esta formulación responde a dos características del problema: (i) los ataques son escasos y heterogéneos (manipulación de actuadores, de lecturas o ambos, con ocultamiento en algunos casos), por lo que un clasificador supervisado tendería a memorizar los ataques vistos; y (ii) los sensores no son independientes, sino que están acoplados por la física hidráulica y por los lazos de control de los PLC, y un ataque suele romper precisamente esas relaciones.

2 Datos

2.1 Conjuntos de BATADAL

El *BATtle of the Attack Detection ALgorithms* (BATADAL) proporciona series horarias simuladas con EPANET sobre la red C-Town (`CTOWN.INP`), con 7 tanques, 11 bombas, 1 válvula y 388 nodos de demanda. Se usan tres conjuntos (Tabla 1).

Tabla 1: Conjuntos de datos y su uso en el protocolo.

Conjunto	Horas	Horas en ataque	Uso
`dataset03` (80 % inicial)	7 008	0	Entrenamiento del VGAE
`dataset03` (20 % final)	1 753	0	Validación y Fase I del SPC
`dataset04`	4 177	492 (ataques 1–7)	Selección de hiperparámetros
Prueba	2 089	407 (ataques 8–14)	Evaluación final

Las etiquetas de `dataset04` provistas en el CSV están incompletas (parte de los ataques se marcó como desconocida), por lo que se reconstruyeron las ventanas completas de cada ataque a partir de la documentación oficial (`Attacks_TrainingDataset4.png` y `Attacks_TestDataset.png`). Así, cada hora tiene una etiqueta $y_t \in \{0, 1\}$ y un identificador de ataque.

2.2 Variables y preprocesamiento

Las 43 señales originales son: niveles de tanque (L_T1–L_T7), caudal y estado de bombas (F_PUi, S_PUi), caudal y estado de la válvula (F_V2, S_V2) y 12 presiones de succión/descarga en uniones (P_J*). Se eliminan las 7 señales con varianza nula en operación normal (bombas PU3, PU5 y PU9, que nunca operan, y S_PU1, siempre encendida), pues no aportan información y harían indefinida la estandarización. Quedan $N = 36$ sensores.

Cada señal se estandariza con la media y desviación típica del tramo de entrenamiento (80 % inicial de `dataset03`):

$$\tilde{x}_{t,i} = \frac{x_{t,i} - \bar{x}_i}{s_i}. \tag{1}$$

Los parámetros se estiman solo con datos de entrenamiento para evitar fuga de información hacia la Fase I, `dataset04` y la prueba.

2.3 Ventanas deslizantes

La entrada al modelo en el instante t es la matriz de atributos de nodo

$$\mathbf{X}_t = [\tilde{\mathbf{x}}_{t-W+1}, \ldots, \tilde{\mathbf{x}}_t] \in \mathbb{R}^{N \times W}, \tag{2}$$

es decir, cada nodo (sensor) lleva como vector de atributos las últimas W horas de su propia señal. La ventana que termina en t es causal: solo usa el pasado, por lo que la detección puede ejecutarse en línea. Las primeras $W-1$ horas de cada serie no tienen puntuación y se consideran sin alarma.

3 Grafo de sensores

3.1 Motivación

Un autoencoder convencional trata el vector de sensores como un conjunto sin estructura. En una red de agua, sin embargo, las relaciones entre sensores son conocidas a priori: el caudal de una bomba y su estado están ligados, la presión de descarga depende de la bomba que la alimenta y el nivel de un tanque gobierna, mediante reglas del PLC, el arranque de ciertas bombas. Codificar ese conocimiento en un grafo $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ con $|\mathcal{V}| = N$ permite que el modelo reconstruya cada sensor a partir de sus vecinos físicamente relacionados, y que la manipulación de un sensor (que rompe su coherencia con los vecinos) produzca un error de reconstrucción localizado.

3.2 Construcción

A partir de `CTOWN.INP` se construye un grafo hidráulico ponderado cuyas aristas son las tuberías (peso = longitud) y las bombas y válvulas (peso unitario). Cada sensor se ubica en un nodo de esa red: los niveles en su tanque, las presiones en su unión y los sensores de bombas/válvulas en su nodo de succión. Con el algoritmo de Dijkstra se obtiene la distancia hidráulica D_{ij} entre todos los pares de sensores. La matriz de adyacencia binaria y simétrica $\mathbf{A} \in \{0,1\}^{N \times N}$ (sin bucles) se forma con la unión de cuatro tipos de arista:

(i) **Mismo dispositivo:** caudal $\leftrightarrow$ estado del mismo equipo (p. ej. *F_PU2–S_PU2*).

(ii) **Estación de bombeo:** presiones y sensores de bombas/válvulas cuya distancia hidráulica es $D_{ij} \leq 5\,\text{m}$, es decir, que pertenecen a la misma estación.

(iii) **Lazos de control:** nivel de tanque $\leftrightarrow$ actuadores que lo controlan según la sección `[CONTROLS]` del archivo de red (T1→PU1, PU2; T2→V2; T3→PU4, PU5; T4→PU6, PU7; T5→PU8; T7→PU10, PU11).

(iv) k **vecinos hidráulicos:** cada sensor se une a los k sensores de otro dispositivo más cercanos en distancia D_{ij}.

Los tres primeros tipos son fijos; k es un hiperparámetro. Con $k = 1$ (configuración seleccionada) el grafo tiene 65 aristas: 8 de dispositivo, 24 de estación, 17 de control y 16 hidráulicas (Figura 1). Como varios sensores comparten ubicación (p. ej. las bombas de una misma estación), existen empates de distancia en el paso (iv); el desempate se fija ordenando de forma estable y la adyacencia usada en el entrenamiento se guarda junto con el modelo para que la evaluación use exactamente el mismo grafo.

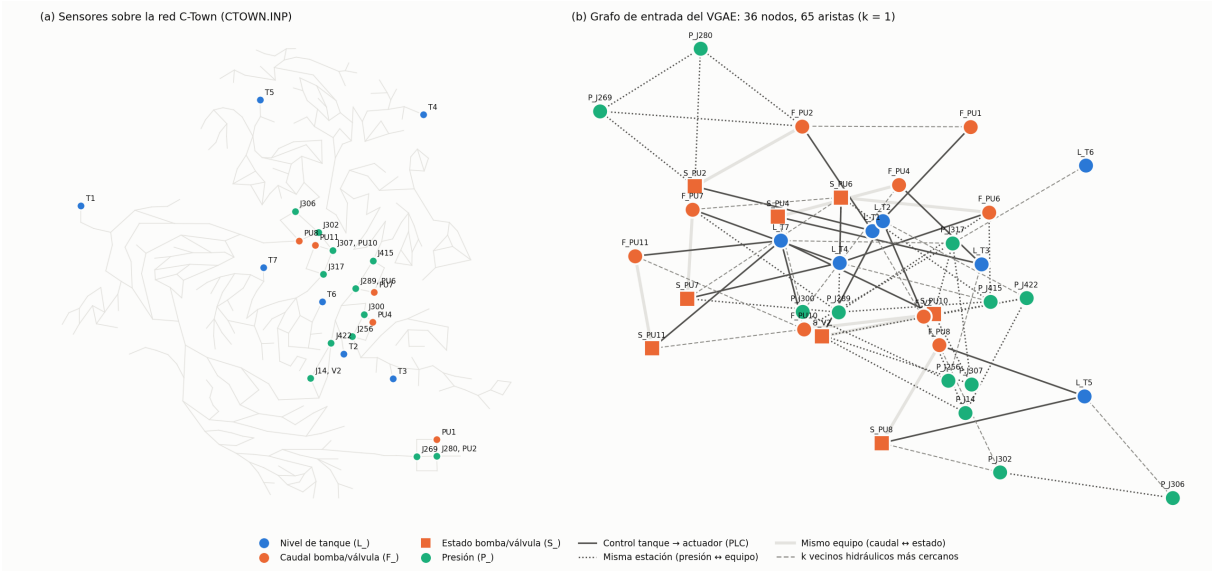


Figura 1: (a) Ubicación de los sensores en la red C-Town. (b) Grafo de entrada del VGAE con los cuatro tipos de arista.

4 Fundamentos teóricos del modelo

4.1 Redes convolucionales sobre grafos

Una red convolucional de grafos (GCN; Kipf y Welling, 2017) generaliza la convolución a datos definidos sobre nodos. Partiendo de la convolución espectral con el laplaciano normalizado y truncando su aproximación de Chebyshev al primer orden, se obtiene la regla de propagación

$$\mathbf{H}^{(l+1)} = \sigma\Big(\hat{\mathbf{A}}\,\mathbf{H}^{(l)}\mathbf{W}^{(l)}\Big), \qquad \hat{\mathbf{A}} = \tilde{\mathbf{D}}^{-1/2}(\mathbf{A}+\mathbf{I})\tilde{\mathbf{D}}^{-1/2}, \tag{3}$$

donde $\tilde{\mathbf{D}} = \operatorname{diag}\big(\sum_j (\mathbf{A}+\mathbf{I})_{ij}\big)$. Cada capa transforma linealmente los atributos de cada nodo y luego los promedia con los de sus vecinos (incluido él mismo, por los bucles añadidos) con pesos normalizados por el grado. La normalización simétrica mantiene los autovalores de $\hat{\mathbf{A}}$ en $(-1, 1]$, lo que estabiliza la propagación al apilar capas. Tras l capas, la representación de un nodo depende de su vecindario a l saltos.

En la implementación, una capa GCN calcula $\hat{\mathbf{A}}(\mathbf{H}\mathbf{W}+\mathbf{b})$ y se aplica de forma independiente a cada ventana del lote, compartiendo $\hat{\mathbf{A}}$, que es fijo.

4.2 Autoencoder variacional

Un autoencoder variacional (VAE; Kingma y Welling, 2014) es un modelo generativo con variables latentes $\mathbf{z}$, prior $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ y verosimilitud $p_\theta(\mathbf{x} \mid \mathbf{z})$. Como la posterior exacta es intratable, se introduce una distribución aproximada $q_\phi(\mathbf{z} \mid \mathbf{x})$ (el *encoder*) y se maximiza la cota inferior de la evidencia (ELBO):

$$\log p_\theta(\mathbf{x}) \;\geq\; \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x} \mid \mathbf{z})] - \mathrm{KL}\big(q_\phi(\mathbf{z} \mid \mathbf{x}) \,\|\, p(\mathbf{z})\big)\,. \tag{4}$$

El primer término favorece reconstrucciones fieles; el segundo regulariza el espacio latente acercándolo al prior, lo que produce representaciones suaves y evita que el modelo memorice cada muestra. Con $q_\phi = \mathcal{N}(\boldsymbol{\mu}, \operatorname{diag}\boldsymbol{\sigma}^2)$ la divergencia tiene forma cerrada,

$$\mathrm{KL} = -\tfrac{1}{2}\sum_{d=1}^{D}\Big(1 + \log\sigma_d^2 - \mu_d^2 - \sigma_d^2\Big)\,, \tag{5}$$

y el gradiente respecto a ϕ se obtiene con el *truco de reparametrización*: $\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\varepsilon}$, $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.

Si la verosimilitud es gaussiana con varianza fija, maximizar el primer término de (4) equivale a minimizar el error cuadrático medio, y la ponderación del término KL por un factor β (β-VAE) controla el compromiso entre fidelidad de reconstrucción y regularidad del espacio latente.

4.3 Variational Graph Autoencoder

El VGAE (Kipf y Welling, 2016) combina ambas ideas: el encoder es una GCN que produce una distribución latente por nodo,

$$q(\mathbf{Z} \mid \mathbf{X}, \mathbf{A}) = \prod_{i=1}^{N} \mathcal{N}\Big(\mathbf{z}_i \mid \boldsymbol{\mu}_i, \operatorname{diag} \boldsymbol{\sigma}_i^2\Big), \qquad \boldsymbol{\mu} = \mathrm{GCN}_{\mu}(\mathbf{X}, \mathbf{A}), \;\; \log \boldsymbol{\sigma}^2 = \mathrm{GCN}_{\sigma}(\mathbf{X}, \mathbf{A}), \tag{6}$$

donde ambas cabezas comparten la primera capa. El decoder original reconstruye la estructura mediante un producto interno,

$$p(A_{ij} = 1 \mid \mathbf{z}_i, \mathbf{z}_j) = \sigma\Big(\mathbf{z}_i^{\top} \mathbf{z}_j\Big), \tag{7}$$

de modo que nodos conectados deben tener representaciones latentes alineadas.

4.4 Adaptación al monitoreo de sensores

En este problema el grafo es fijo y lo que cambia en el tiempo son los atributos de los nodos. Reconstruir solo $\mathbf{A}$ no daría información sobre el estado del proceso, por lo que se introducen tres modificaciones al VGAE original.

Decoder de atributos. Se añade un segundo decoder que reconstruye la ventana temporal de cada sensor:

$$\hat{\mathbf{X}} = \mathrm{ReLU}\Big(\hat{\mathbf{A}}\,[\mathbf{Z} \,\|\, \mathbf{E}]\,\mathbf{W}_d\Big)\,\mathbf{W}_o, \qquad \hat{\mathbf{X}} \in \mathbb{R}^{N \times W}. \tag{8}$$

Al ser también una GCN, el valor reconstruido de un sensor se apoya en el estado latente de sus vecinos. Si un atacante altera la lectura de un sensor sin alterar coherentemente la de sus vecinos (o viceversa), la reconstrucción falla precisamente en ese nodo.

Embeddings de nodo. La GCN es invariante a permutaciones: dos nodos con atributos y vecindarios similares reciben la misma representación. Sin embargo, una presión y un nivel de tanque tienen dinámicas muy distintas. Para que el modelo distinga la identidad de cada sensor se aprende un vector $\mathbf{e}_i \in \mathbb{R}^{d_e}$ por nodo, que se concatena a la entrada del encoder y a la del decoder de atributos ($\mathbf{E} = [\mathbf{e}_1, \ldots, \mathbf{e}_N]^{\top}$).

Decoder de estructura como regularizador. Se conserva el decoder de producto interno, pero con un peso α pequeño: obliga a que el espacio latente refleje la topología, sin dominar la pérdida.

Arquitectura. El modelo resultante (Figura 2) es:

$$\begin{aligned}
&\mathbf{H} = \mathrm{ReLU}(\hat{\mathbf{A}}\,[\mathbf{X} \,\|\, \mathbf{E}]\,\mathbf{W}_1) && (W + d_e) \to h,\\
&\boldsymbol{\mu} = \hat{\mathbf{A}}\,\mathbf{H}\mathbf{W}_{\mu}, \quad \log \boldsymbol{\sigma}^2 = \mathrm{clip}(\hat{\mathbf{A}}\,\mathbf{H}\mathbf{W}_{\sigma},\, -10,\, 10) && h \to d_z,\\
&\mathbf{Z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\varepsilon} \text{ (entrenamiento)}, \qquad \mathbf{Z} = \boldsymbol{\mu} \text{ (inferencia)}, &&\\
&\hat{\mathbf{X}} = \mathrm{ReLU}(\hat{\mathbf{A}}\,[\mathbf{Z} \,\|\, \mathbf{E}]\,\mathbf{W}_d)\mathbf{W}_o && (d_z + d_e) \to h \to W,\\
&\hat{A}_{ij} = \sigma(\mathbf{z}_i^{\top} \mathbf{z}_j). &&
\end{aligned}$$

En inferencia se usa la media $\boldsymbol{\mu}$ (sin muestreo), lo que hace el puntaje determinista.

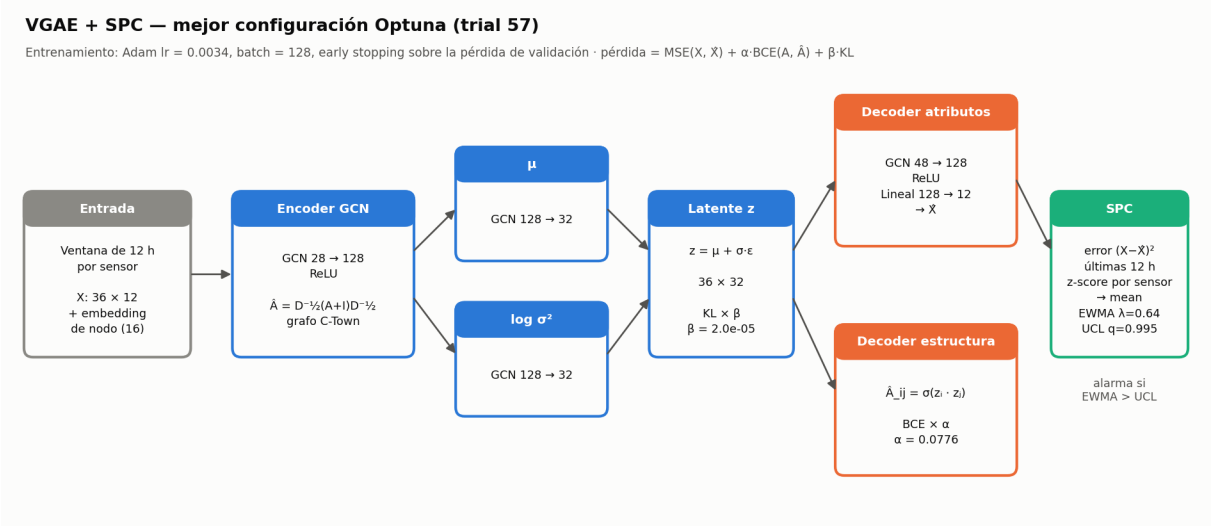


Figura 2: Arquitectura VGAE + SPC con la configuración seleccionada.

4.5 Variante con convolución temporal

En la arquitectura base, la ventana de W horas de cada sensor entra como un vector plano de atributos: la primera capa la mezcla con una transformación lineal que no incorpora el orden temporal ni la invariancia a desplazamientos, el modelo no tiene memoria entre ventanas y desconoce la hora del día. Para modelar la dimensión temporal de forma explícita se propone una variante que intercala bloques convolucionales sobre el eje del tiempo con la convolución de grafo, en la línea de las redes espacio-temporales STGCN (Yu et al., 2018) y de las redes convolucionales temporales (TCN; Bai et al., 2018).

Codificación de la hora del día. La demanda de agua sigue un ciclo diario que una ventana de 12 h no cubre completo. Cada instante se acompaña de $\big(\sin(2\pi h/24), \cos(2\pi h/24)\big)$, con h la hora, de modo que el modelo conoce la fase del ciclo sin depender solo de los valores observados. La codificación circular evita la discontinuidad entre las 23 h y las 0 h.

Encoder temporal. Para cada sensor i, la serie de la ventana y la hora del día forman una señal de 3 canales y longitud W, que pasa por una pila de convoluciones 1D dilatadas con conexión residual:

$$\mathbf{u}^{(b)} = \mathrm{ReLU}\Big(\mathrm{Conv1D}_{k=3,\,d_b}\big(\mathbf{u}^{(b-1)}\big) + \mathbf{P}_b\,\mathbf{u}^{(b-1)}\Big), \qquad d_b \in \{1, 2, 4\}, \tag{9}$$

donde $\mathbf{P}_b$ es una proyección 1×1 cuando cambia el número de canales. Con núcleo 3 y dilataciones 1, 2 y 4, el campo receptivo es $1+2(1+2+4) = 15 \geq W$, por lo que cada posición ve la ventana completa. A diferencia de la capa lineal, los filtros se comparten a lo largo del tiempo (invariancia a desplazamientos) y respetan el orden de las horas. La salida, $C = 16$ canales por instante, se aplana a un vector de $C \cdot W$ atributos por nodo, que sustituye a la ventana cruda como entrada de la GCN; el resto del encoder no cambia.

Decoder temporal. El decoder de atributos aplica el bloque espejo: la salida de la GCN se proyecta a $C \cdot W$, se reorganiza como C canales de longitud W, se concatena con la hora del día y pasa por convoluciones dilatadas ($d = 4, 2, 1$) y una convolución 1×1 que devuelve un canal: la ventana reconstruida $\hat{\mathbf{x}}_i \in \mathbb{R}^W$.

Qué no cambia. El grafo, la normalización $\hat{\mathbf{A}}$, el espacio latente, la función de pérdida, el estadístico por sensor y las cartas de control son idénticos, lo que permite atribuir cualquier diferencia de desempeño al tratamiento del tiempo. La variante tiene unos 71 000 parámetros frente a 20 000 del modelo base.

4.6 Función de pérdida

Para un lote de ventanas, la pérdida es

$$\mathcal{L} = \underbrace{\frac{1}{NW}\|\mathbf{X} - \hat{\mathbf{X}}\|_F^2}_{\text{atributos (MSE)}} + \alpha \underbrace{\mathrm{BCE}_w(\mathbf{A}, \sigma(\mathbf{Z}\mathbf{Z}^\top))}_{\text{estructura}} + \beta \underbrace{\frac{1}{N}\sum_{i=1}^{N} \mathrm{KL}\left(q(\mathbf{z}_i) \,\|\, \mathcal{N}(\mathbf{0}, \mathbf{I})\right)}_{\text{regularización}}, \tag{10}$$

promediada sobre el lote. La entropía cruzada binaria se pondera con $w = (N^2 - \sum_{ij} A_{ij}) / \sum_{ij} A_{ij}$ en las entradas positivas para compensar la dispersión del grafo (hay muchas más no-aristas que aristas). Esta pérdida es el negativo de una ELBO con verosimilitud gaussiana para los atributos, Bernoulli para la estructura y pesos α, β en los dos últimos términos.

4.7 Por qué el error de reconstrucción detecta ataques

El modelo se entrena solo con operación normal, de modo que aprende la variedad de baja dimensión en la que viven las ventanas normales y las correlaciones entre sensores vecinos. Una ventana anómala cae fuera de esa variedad: el encoder la proyecta sobre el código latente normal más cercano y el decoder devuelve una versión "normal" de la ventana. La diferencia

$$\mathbf{R}_t = (\mathbf{X}_t - \hat{\mathbf{X}}_t)^{\odot 2} \in \mathbb{R}^{N \times W} \tag{11}$$

mide la desviación respecto al comportamiento aprendido, con resolución por sensor y por hora. Dado que el grafo condiciona la reconstrucción, el error no solo detecta valores atípicos aislados, sino también inconsistencias entre sensores que por separado parecen normales (por ejemplo, un nivel de tanque falsificado que no concuerda con el caudal de las bombas que lo alimentan).

5 Control estadístico de procesos sobre las salidas del VGAE

El VGAE proporciona residuos y representaciones latentes; el SPC proporciona la regla de decisión con una tasa de falsas alarmas controlada. Todas las cartas se calibran en *Fase I* (20 % final de `dataset03`: operación normal que el modelo no usó para ajustar sus pesos) y se aplican en *Fase II* (`dataset04` y prueba).

5.1 Criterios para elegir las cartas

Qué se vigila: residuo y espacio latente. En el monitoreo multivariante basado en PCA (Jackson y Mudholkar, 1979; Kourti y MacGregor, 1995) se usan dos estadísticos complementarios: el error de predicción Q (SPE), que detecta observaciones que *rompen la estructura de correlación* aprendida, y el T^2 de Hotelling sobre las componentes principales, que detecta observaciones *coherentes con esa estructura pero en una zona inusual* del subespacio del modelo. El VGAE cumple el papel del PCA, de forma no lineal y respetando el grafo, por lo que se mantiene la misma lógica:

- **Residuo** (EWMA y SPE). Un ataque que falsifica lecturas (p. ej. un nivel de tanque que no concuerda con los caudales de sus bombas) rompe la coherencia física entre sensores vecinos y eleva el error de reconstrucción.

- **Espacio latente** (T^2). Un ataque que manipula actuadores o consignas del PLC puede producir una operación físicamente coherente (el modelo la reconstruye bien) pero en un régimen anormal; este caso se refleja en el estado latente.

Qué tipo de desviación: memoria en la carta del residuo. Los ataques de BATADAL, en particular los que ocultan la manipulación, producen desviaciones moderadas que se sostienen durante horas o días. Las cartas sin memoria son poco sensibles a este tipo de desplazamiento (Montgomery, 2019, cap. 9), por lo que para el estadístico del residuo se usa una EWMA, que acumula evidencia en el tiempo.

Cartas descartadas.

- **Shewhart**: es el caso particular $\lambda = 1$ de la EWMA. Ese valor se incluye en la búsqueda de λ, de modo que si los datos favorecieran una carta sin memoria la búsqueda lo seleccionaría; calcularla por separado es redundante. Como referencia se reporta la mejor configuración de la rejilla con $\lambda = 1$.
- **CUSUM**: para detectar desplazamientos pequeños y sostenidos de la media su desempeño es prácticamente equivalente al de la EWMA (Lucas y Saccucci, 1990), por lo que no aporta información adicional y añadiría un parámetro más (k) que ajustar con los mismos datos.

5.2 Estadístico por sensor

Para cada sensor i se promedia el error de reconstrucción de las últimas L horas de la ventana, se toma logaritmo y se estandariza con la media m_i y desviación s_i observadas en Fase I:

$$r_{t,i} = \frac{1}{L} \sum_{\ell=W-L+1}^{W} R_{t,i\ell}, \qquad z_{t,i} = \frac{\log(r_{t,i} + 10^{-6}) - m_i}{s_i}. \tag{12}$$

- El **horizonte** $L \leq W$ enfoca el estadístico en las horas más recientes, que son las relevantes para una detección temprana.
- El **logaritmo** reduce la fuerte asimetría a la derecha del error cuadrático y acerca su distribución a la normal.
- La **estandarización por sensor** hace comparables sensores con niveles de error muy distintos; sin ella, unos pocos sensores difíciles de reconstruir dominarían el estadístico y un ataque localizado (p. ej. solo sobre L_T2 y $V2$) se diluiría entre los 36 nodos.

Los $z_{t,i}$ se agregan en un escalar s_t mediante la media (`mean`), el máximo (`max`) o la media de los tres mayores (`top3`). La media es sensible a desviaciones moderadas y extendidas; el máximo, a desviaciones fuertes en un único sensor; `top3` es un compromiso.

5.3 Límites de control empíricos

Los límites teóricos de las cartas clásicas suponen observaciones independientes. Las series monitoreadas están fuertemente autocorrelacionadas, porque ventanas consecutivas comparten $W - 1$ horas, y aplicar esos límites produciría un exceso de falsas alarmas. Por ello, para la EWMA y el T^2 el límite superior se define como el cuantil empírico q del estadístico de la carta calculado sobre Fase I:

$$\mathrm{UCL} = Q_q\big(\{C_t\}_{t \in \text{Fase I}}\big), \qquad q \in \{0.99,\, 0.995,\, 0.999\}, \tag{13}$$

lo que fija la tasa nominal de falsas alarmas en $1 - q$. Se emite alarma en t si $C_t > \mathrm{UCL}$.

5.4 Carta EWMA sobre el residuo

$$C_t = \lambda s_t + (1-\lambda) C_{t-1}, \qquad C_0 = \bar{s}_{\text{Fase I}}, \quad \lambda \in (0, 1]. \tag{14}$$

La EWMA es un promedio ponderado de todas las observaciones pasadas con pesos que decaen geométricamente, $C_t = \lambda \sum_{j \geq 0} (1-\lambda)^j s_{t-j}$, con memoria efectiva de $\approx (2-\lambda)/\lambda$ observaciones: con λ pequeño se acumula evidencia de desplazamientos pequeños y sostenidos, y con $\lambda = 1$ se obtiene la carta de Shewhart. Al promediar, es además robusta a la falta de normalidad del estadístico (Borror et al., 1999). La carta es *unilateral*: solo un aumento del error de reconstrucción indica ataque. Es la carta principal del estudio.

5.5 Carta T^2 de Hotelling sobre el espacio latente

Cada ventana se resume con el embedding del grafo $\bar{\boldsymbol{\mu}}_t = \frac{1}{N} \sum_i \boldsymbol{\mu}_{t,i} \in \mathbb{R}^{d_z}$ (promedio de las medias latentes de los nodos) y se mide su distancia de Mahalanobis a la operación normal:

$$T_t^2 = (\bar{\boldsymbol{\mu}}_t - \mathbf{m})^\top \mathbf{S}^+ (\bar{\boldsymbol{\mu}}_t - \mathbf{m}), \tag{15}$$

donde $\mathbf{m}$ y $\mathbf{S}$ son la media y la covarianza muestral de $\bar{\boldsymbol{\mu}}_t$ en Fase I y $\mathbf{S}^+$ su pseudoinversa. El T^2 es la versión multivariante de la carta de Shewhart; usar la distancia de Mahalanobis, y no la euclídea, tiene en cuenta la correlación entre las dimensiones latentes. Vigila desplazamientos del estado latente (el régimen en que el modelo "cree" que está el sistema), información que el error de reconstrucción no captura.

5.6 Carta SPE (estadístico Q)

Es la carta clásica para el residuo en el MSPC: el error cuadrático de predicción sumado sobre sensores,

$$Q_t = \sum_{i=1}^{N} r_{t,i}, \tag{16}$$

con el límite de Box (1954), usado en PCA multivariante por Nomikos y MacGregor (1995), que aproxima la distribución de Q por una $g\,\chi^2_h$ con la media m y la varianza v de Fase I:

$$g = \frac{v}{2m}, \qquad h = \frac{2m^2}{v}, \qquad \text{UCL} = g\,\chi^2_h(q). \tag{17}$$

Se incluye como referencia frente a la EWMA. Hay que tener en cuenta dos limitaciones: la aproximación χ^2 supone residuos gaussianos de un modelo lineal, lo que el VGAE no garantiza, y al sumar el error sin estandarizar, los sensores con mayor error de reconstrucción dominan el estadístico. El estadístico estandarizado por sensor de la Sección 5.2 responde precisamente a esta segunda limitación.

5.7 Regla combinada

Siguiendo la práctica del MSPC de vigilar simultáneamente el residuo y el subespacio del modelo, se evalúa la regla "EWMA o T^2", que alarma si cualquiera de las dos cartas supera su límite.

6 Métrica de evaluación

Se usa la métrica oficial de BATADAL, que combina la rapidez de detección y la calidad de la clasificación:

$$S = \tfrac{1}{2}\, S_{\text{TTD}} + \tfrac{1}{2}\, S_{\text{CM}}. \tag{18}$$

- **Tiempo hasta la detección.** Para cada ataque a de duración Δt_a horas, TTD_a es el número de horas entre su inicio y la primera alarma dentro de su ventana ($\mathrm{TTD}_a = \Delta t_a$ si no se detecta). Entonces

$$S_{\mathrm{TTD}} = 1 - \frac{1}{n_A} \sum_{a=1}^{n_A} \frac{\mathrm{TTD}_a}{\Delta t_a}. \tag{19}$$

- **Matriz de confusión.** A nivel horario,

$$S_{\mathrm{CM}} = \frac{\mathrm{TPR} + \mathrm{TNR}}{2}, \qquad \mathrm{TPR} = \frac{TP}{TP + FN}, \quad \mathrm{TNR} = \frac{TN}{TN + FP}. \tag{20}$$

Se reportan además precisión, F_1 y número de ataques detectados.

7 Protocolo experimental

7.1 Entrenamiento

El VGAE se entrena con Adam minimizando (10) sobre las ventanas del 80 % inicial de `dataset03`, en mini-lotes barajados en cada época. Se aplica *early stopping* sobre la pérdida en el 20 % final (hasta 300 épocas, paciencia de 25) y se restauran los pesos de la mejor época. Ese mismo tramo, que el optimizador nunca ve, sirve como Fase I del SPC. En la práctica el criterio de parada casi nunca se activó: la mediana de épocas en los ensayos de Optuna fue 300 y el modelo final alcanzó su mejor pérdida de validación en la época 297.

7.2 Optimización de hiperparámetros

Los hiperparámetros del VGAE y de la carta EWMA se seleccionan conjuntamente con Optuna (Tabla 2), maximizando S en `dataset04`. El conjunto de prueba no interviene en ninguna decisión.

Tabla 2: Espacio de búsqueda y configuración seleccionada.

Grupo	Hiperparámetro	Espacio	Seleccionado
Entrada y grafo	Ventana W (h)	$\{12, 24, 48\}$	12
	Vecinos hidráulicos k	$\{1, \ldots, 5\}$	1
Arquitectura	Capa oculta h	$\{32, 64, 128\}$	128
	Dimensión latente d_z	$\{4, 8, 16, 32\}$	32
	Embedding de nodo d_e	$\{4, 8, 16\}$	16
Entrenamiento	Tasa de aprendizaje	$[10^{-4}, 5 \cdot 10^{-3}]$ (log)	$3.36 \cdot 10^{-3}$
	Tamaño de lote	$\{128, 256, 512\}$	128
	Peso estructura α	$[10^{-3}, 1]$ (log)	0.078
	Peso KL β	$[10^{-5}, 10^{-1}]$ (log)	$2.0 \cdot 10^{-5}$
Carta EWMA	Horizonte L (h)	$\{1, 3, 6, 12\}$	12
	Agregación	{mean, max, top3}	mean
	λ	[0.05, 1] (log)	0.645
	Cuantil q	$\{0.99, 0.995, 0.999\}$	0.995

El muestreador principal es el *Tree-structured Parzen Estimator* (TPE) multivariante. TPE modela por separado la densidad de los hiperparámetros en los mejores ensayos, $\ell(\boldsymbol{\theta})$, y en el resto, $g(\boldsymbol{\theta})$, y propone el candidato que maximiza $\ell(\boldsymbol{\theta})/g(\boldsymbol{\theta})$, que es proporcional a la mejora

esperada. La variante multivariante modela las dependencias entre hiperparámetros. Se ejecutaron 100 ensayos, de los cuales los 10 primeros fueron aleatorios.

Para comprobar que la configuración elegida no es fruto del azar se aplicaron tres controles:

1. **Búsqueda aleatoria de control** (50 ensayos, mismo espacio y objetivo), comparada con TPE mediante la prueba U de Mann–Whitney unilateral.

2. **Importancia de hiperparámetros** mediante fANOVA, que descompone la varianza de S entre los hiperparámetros sobre un bosque aleatorio ajustado a los ensayos.

3. **Robustez frente a la semilla:** la mejor configuración TPE, la mejor aleatoria y la configuración por defecto se reentrenan con 10 semillas nuevas (100–109). Solo en esta etapa se evalúa el conjunto de prueba, y las diferencias se contrastan con la prueba de Wilcoxon de rangos con signo, pareada por semilla.

7.3 Comparación de cartas

Con el VGAE seleccionado y entrenado, los parámetros de cada carta se reajustan por búsqueda en rejilla sobre `dataset04`, pues los pesos finales del modelo difieren de los del ensayo de Optuna:

- EWMA: $L \in \{1, 3, 6, 12\}$, agregación $\in \{\texttt{mean}, \texttt{max}, \texttt{top3}\}$, $\lambda \in \{0.05, 0.1, 0.2, 0.5, 1\}$ y $q \in \{0.99, 0.995, 0.999\}$.
- T^2: $q \in \{0.99, 0.995, 0.999\}$.
- SPE: $L \in \{1, 3, 6, 12, 24\}$ y $q \in \{0.99, 0.995, 0.999\}$.
- Regla combinada: EWMA y T^2 con sus configuraciones elegidas.

La inclusión de $\lambda = 1$ permite contrastar con los datos si la memoria aporta frente a la carta de Shewhart; por eso se reporta también la mejor configuración con $\lambda = 1$. Como referencia se evalúa además la EWMA con los parámetros elegidos por Optuna. La configuración elegida se aplica sin cambios al conjunto de prueba.

7.4 Evaluación de la convolución temporal

La variante de la Sección 4.5 se compara con el modelo base mediante un diseño pareado: ambas usan los hiperparámetros seleccionados por Optuna, el mismo grafo, el mismo presupuesto de entrenamiento y las mismas semillas, y se evalúan con la carta EWMA con los parámetros de Optuna. La única diferencia es el bloque temporal. Los hiperparámetros se eligieron para el modelo base, de modo que la comparación es conservadora respecto de la variante temporal.

Ambos modelos se entrenan con el mismo presupuesto que la búsqueda y el modelo final (hasta 300 épocas, paciencia 25), con 10 semillas (100–109) y con la adyacencia guardada en el modelo final, y las diferencias se contrastan con la prueba de Wilcoxon pareada por semilla.

La variante temporal obtiene menor pérdida de validación (0.149 frente a 0.161) y converge antes: el *early stopping* la detiene en una mediana de 170 épocas, mientras que el modelo base agota las 300. En detección, la S media en prueba pasa de 0.741 ± 0.016 a 0.758 ± 0.025 ($+0.016$; gana en 7 de 10 semillas) y en `dataset04` de 0.855 a 0.866 ($+0.011$; 6 de 10), sin significancia estadística (Wilcoxon bilateral, $p = 0.13$ y $p = 0.19$). Una comparación preliminar con 40 épocas y 2 semillas había mostrado $+0.086$ en prueba; con el presupuesto completo la ventaja se reduce a una quinta parte, lo que indica que procedía sobre todo de una convergencia más rápida.

7.5 Diagnóstico

Como el estadístico (12) está definido por sensor, la matriz $z_{t,i}$ permite atribuir cada alarma a los sensores que más contribuyen a ella. Para cada ataque de prueba se reportan los sensores con mayor z medio, lo que permite contrastar la detección con el componente realmente atacado y apoya la interpretabilidad del detector para el operador. La comparación debe hacerse frente al z medio de cada sensor en las horas normales del mismo conjunto: los sensores del subsistema T1–PU1/PU2 tienen un z medio de 1.1–1.9 también fuera de los ataques, por lo que valores de ese orden en ellos no indican ataque.

7.6 Resumen del procedimiento

1. Cargar los datos, reconstruir etiquetas y eliminar sensores constantes.
2. Construir $\mathbf{A}$ a partir de `CTOWN.INP` y calcular $\hat{\mathbf{A}}$.
3. Estandarizar con estadísticos del tramo de entrenamiento y formar ventanas de W horas.
4. Entrenar el VGAE con operación normal (early stopping en Fase I).
5. Calcular residuos $\mathbf{R}_t$ y embeddings $\bar{\boldsymbol{\mu}}_t$ en Fase I, `dataset04` y prueba.
6. Calibrar m_i, s_i y los límites de control en Fase I.
7. Elegir hiperparámetros maximizando S en `dataset04`.
8. Evaluar una única vez en el conjunto de prueba.

Referencias

Akiba, T., Sano, S., Yanase, T., Ohta, T. y Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *KDD*.

Bai, S., Kolter, J. Z. y Koltun, V. (2018). An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv:1803.01271*.

Bergstra, J., Bardenet, R., Bengio, Y. y Kégl, B. (2011). Algorithms for hyper-parameter optimization. *NeurIPS*.

Borror, C. M., Montgomery, D. C. y Runger, G. C. (1999). Robustness of the EWMA control chart to non-normality. *Journal of Quality Technology*, 31(3).

Box, G. E. P. (1954). Some theorems on quadratic forms applied in the study of analysis of variance problems. *Annals of Mathematical Statistics*, 25(2).

Hutter, F., Hoos, H. y Leyton-Brown, K. (2014). An efficient approach for assessing hyperparameter importance. *ICML*.

Jackson, J. E. y Mudholkar, G. S. (1979). Control procedures for residuals associated with principal component analysis. *Technometrics*, 21(3).

Kingma, D. P. y Welling, M. (2014). Auto-encoding variational Bayes. *ICLR*.

Kipf, T. N. y Welling, M. (2016). Variational graph auto-encoders. *NeurIPS Workshop on Bayesian Deep Learning*.

Kipf, T. N. y Welling, M. (2017). Semi-supervised classification with graph convolutional networks. *ICLR*.

Kourti, T. y MacGregor, J. F. (1995). Process analysis, monitoring and diagnosis, using multivariate projection methods. *Chemometrics and Intelligent Laboratory Systems*, 28(1).

Lucas, J. M. y Saccucci, M. S. (1990). Exponentially weighted moving average control schemes: properties and enhancements. *Technometrics*, 32(1).

Montgomery, D. C. (2019). *Introduction to Statistical Quality Control* (8.ª ed.). Wiley.

Nomikos, P. y MacGregor, J. F. (1995). Multivariate SPC charts for monitoring batch processes. *Technometrics*, 37(1).

Taormina, R., Galelli, S., Tippenhauer, N. O. et al. (2018). Battle of the Attack Detection Algorithms: Disclosing cyber attacks on water distribution networks. *Journal of Water Resources Planning and Management*, 144(8).

Yu, B., Yin, H. y Zhu, Z. (2018). Spatio-temporal graph convolutional networks: a deep learning framework for traffic forecasting. *IJCAI*.