Detección de ciberataques con un *Variational Graph Autoencoder* y control estadístico de procesos

Jorge Proaño Salvador Naya Javier Tarrío Miguel Flores

Universidad de La Coruña

Borrador — 9 de noviembre de 2026

Resumen

Los sistemas de distribución de agua operados por SCADA son vulnerables a ciberataques que manipulan actuadores y falsifican lecturas para ocultar la manipulación. Proponemos un detector semisupervisado que combina un *Variational Graph Autoencoder* (VGAE) con cartas de control estadístico de procesos (SPC). Los 36 sensores informativos de la red C-Town se representan como nodos de un grafo construido a partir de la topología hidráulica y de la lógica de control de los PLC; el VGAE, entrenado solo con operación normal, reconstruye ventanas temporales de cada sensor apoyándose en sus vecinos físicos. Siguiendo el esquema del control multivariante basado en PCA, el error de reconstrucción, estandarizado por sensor, se vigila con una carta EWMA, el espacio latente con el T^2 de Hotelling y el residuo crudo con la carta SPE. Los hiperparámetros se seleccionan con optimización bayesiana (TPE) sobre el conjunto `dataset04` de BATADAL y el conjunto de prueba se reserva para la evaluación final. La búsqueda TPE supera claramente a la aleatoria ($p = 3.1 \cdot 10^{-19}$) y su configuración es estable frente a la semilla (S en prueba 0.750 ± 0.017 frente a 0.529 ± 0.035 de la configuración por defecto, 10 semillas). Con el modelo final, la regla combinada EWMA $\vee$ T^2 detecta los 7 ataques de prueba con $S = 0.819$ (TPR 0.651, TNR 0.929, $F_1 = 0.669$). El estadístico por sensor atribuye las alarmas a la zona atacada de la red, incluso cuando el atacante oculta las lecturas del componente comprometido. Una variante con convolución temporal converge antes, pero su mejora en prueba (+0.016 en S, 7 de 10 semillas) no es significativa. Discutimos además la sensibilidad de la métrica de BATADAL a la densidad de alarmas y las causas por las que la tasa de falsas alarmas observada supera la nominal fijada en Fase I.

Palabras clave: ciberseguridad de sistemas ciberfísicos; detección de anomalías; redes neuronales de grafos; autoencoder variacional; control estadístico de procesos; BATADAL.

1 Introducción

Los sistemas de distribución de agua dependen cada vez más de redes SCADA y de controladores lógicos programables (PLC) conectados, lo que los expone a ataques que pueden alterar consignas, activar o detener bombas y falsificar las lecturas que recibe el operador. Este último aspecto es el que hace difícil la detección: un atacante que repite lecturas pasadas (*replay*) o compensa sus efectos sobre los sensores puede mantener una apariencia de normalidad en las variables del componente atacado.

La *BATtle of the Attack Detection ALgorithms* (BATADAL) [23] estableció un banco de pruebas común para este problema sobre la red C-Town, con datos horarios simulados en EPANET, ataques etiquetados y una métrica oficial que combina el tiempo de detección con la calidad de la clasificación. Los enfoques presentados abarcan desde modelos hidráulicos explícitos [8] hasta métodos de aprendizaje automático [1] y autoencoders profundos [22].

Este trabajo parte de dos observaciones. Primero, los sensores de una red de agua no son variables independientes: están acoplados por la física hidráulica y por los lazos de control, y

un ataque suele romper precisamente esas relaciones. Un modelo que reconstruya cada sensor a partir de sus vecinos físicos debería, por tanto, fallar de forma localizada cuando una lectura deja de ser coherente con su entorno. Segundo, convertir una puntuación de anomalía en una alarma es un problema de decisión con una larga tradición en el control estadístico de procesos (SPC), que ofrece reglas con tasa de falsas alarmas controlada y cartas con memoria para desviaciones pequeñas y sostenidas, típicas de los ataques con ocultamiento.

Contribuciones.

1. Un VGAE con decoder de atributos y *embeddings* de nodo para monitoreo de series multivariantes, sobre un grafo de sensores construido a partir del archivo de red (`CTOWN.INP`) que combina vecindad hidráulica, estaciones de bombeo y lazos de control de los PLC.
2. Un esquema de monitoreo que traslada la lógica del MSPC basado en PCA al VGAE: un estadístico de residuo estandarizado por sensor vigilado con una carta EWMA, el T^2 de Hotelling sobre el espacio latente y la carta SPE como referencia clásica.
3. Un protocolo de selección de hiperparámetros con evidencia estadística de que la configuración elegida no es fruto del azar: comparación TPE frente a búsqueda aleatoria, importancia fANOVA y reentrenamiento con 10 semillas.
4. Un análisis de interpretabilidad que atribuye cada ataque a los sensores que más contribuyen a la alarma, y una discusión crítica de la métrica de BATADAL y de la calibración de los límites de control.

2 Trabajos relacionados

Detección de ataques en redes de agua. En BATADAL [23] participaron siete equipos, con puntuaciones S entre 0.534 y 0.970 en el conjunto de prueba. Los mejores resultados correspondieron a enfoques que combinaban conocimiento del sistema con detección estadística, como el modelo hidráulico de Housh y Ohar [8], o con aprendizaje automático, como Abokifa et al. [1]. Taormina y Galelli [22] emplearon autoencoders densos sobre el vector de sensores, mostrando que el error de reconstrucción permite detectar y localizar ataques. En instalaciones de tratamiento como SWaT [7] se han usado redes convolucionales 1D [16] y recurrentes [9].

Redes neuronales de grafos para anomalías en series multivariantes. Las GCN [14] y el VGAE [13] se propusieron para datos relacionales estáticos. En series multivariantes, GDN [6] aprende un grafo entre sensores y predice cada uno a partir de sus vecinos; las redes espacio-temporales [24] intercalan convoluciones de grafo y temporales. A diferencia de GDN, aquí el grafo no se aprende sino que se deriva del conocimiento físico de la red, lo que reduce los parámetros y hace interpretable la propagación.

Control estadístico multivariante. El MSPC basado en PCA vigila el residuo con el estadístico Q (SPE) y el subespacio del modelo con el T^2 de Hotelling [11, 15, 19]. La carta EWMA [21] acumula evidencia en el tiempo y es más sensible que la de Shewhart a desplazamientos pequeños y sostenidos [18]; para ese tipo de desplazamiento su desempeño es prácticamente equivalente al de la CUSUM [20, 17]. Nuestro trabajo sustituye el PCA por un VGAE, no lineal y consciente del grafo, manteniendo la lógica residuo/latente.

3 Caso de estudio y datos

C-Town es una red de distribución con 7 tanques, 11 bombas, 1 válvula y 388 nodos de demanda, controlada por 9 PLC. BATADAL proporciona tres conjuntos de lecturas horarias (Tabla 1). El

Tabla 1: Conjuntos de datos y su uso en el protocolo experimental.

Conjunto	Horas	Horas en ataque	Uso
`dataset03` (80 % inicial)	7 008	0	Entrenamiento del VGAE
`dataset03` (20 % final)	1 753	0	*Early stopping* y Fase I del SPC
`dataset04`	4 177	492 (ataques 1–7)	Selección de hiperparámetros
Prueba	2 089	407 (ataques 8–14)	Evaluación final

Tabla 2: Ataques del conjunto de prueba (resumen de la documentación oficial de BATADAL).

ID	Horas	Descripción	Ocultamiento en SCADA
8	70	Cambio de umbrales de L_T3 (control de PU4/PU5) vía PLC3; niveles bajos en T3.	*Replay* de L_T3 y caudal/estado de PU4/PU5.
9	65	Alteración de L_T2 hacia PLC3: V2 permanece abierta y T2 desborda.	Polilínea que compensa el aumento de L_T2.
10	31	Activación maliciosa de la bomba PU3.	—
11	31	Similar al ataque 10.	—
12	100	Similar al ataque 9.	*Replay* de L_T2, V2, P_J14, P_J422.
13	80	Cambio de umbrales de L_T7 (PU10/PU11) vía PLC5; encendido/apagado continuo.	*Replay* de L_T7, PU10/PU11, P_J14, P_J422.
14	30	Alteración de la señal de T4 hacia PLC6; desborde de T6.	—

conjunto `dataset03` contiene solo operación normal; `dataset04` contiene los ataques 1–7 y el conjunto de prueba los ataques 8–14 (Tabla 2). En la competición, `dataset04` se entregó con etiquetas parciales: un ataque revelado por completo y el resto parcial o totalmente ocultos [23]. En este trabajo las ventanas de los siete ataques se reconstruyeron a partir de la documentación publicada tras la competición. Las etiquetas de prueba resultantes (407 horas en ataque y 1 682 normales) coinciden con las usadas en la evaluación oficial [23].

De las 43 señales se eliminan las 7 con varianza nula en operación normal (bombas PU3, PU5 y PU9, que nunca operan, y S_PU1, siempre encendida), con lo que quedan $N = 36$ sensores: niveles de tanque, caudales y estados de bombas y válvula, y presiones de succión/descarga. Cada señal se estandariza con media y desviación del tramo de entrenamiento. La entrada del modelo en el instante t es la matriz causal $\mathbf{X}_t = [\tilde{\mathbf{x}}_{t-W+1}, \ldots, \tilde{\mathbf{x}}_t] \in \mathbb{R}^{N \times W}$: cada nodo lleva como atributos las últimas W horas de su señal.

Nótese que la bomba PU3, objetivo de los ataques 10 y 11, no tiene sensores propios en el modelo (fue eliminada por varianza nula), de modo que esos ataques solo pueden detectarse a través de su efecto sobre el resto de la red.

4 Método

4.1 Grafo de sensores

A partir de `CTOWN.INP` se construye un grafo hidráulico (tuberías ponderadas por longitud; bombas y válvulas con peso unitario), se ubica cada sensor en un nodo de esa red y se calcula la distancia hidráulica D_{ij} entre sensores con Dijkstra. La adyacencia binaria y simétrica $\mathbf{A} \in \{0,1\}^{N \times N}$ es la unión de cuatro tipos de arista: (i) caudal–estado del mismo dispositivo; (ii) sensores de la misma estación de bombeo ($D_{ij} \leq 5\,\mathrm{m}$); (iii) lazos de control según la sección `[CONTROLS]` (p. ej. T1→PU1, PU2; T2→V2; T7→PU10, PU11); y (iv) los k vecinos hidráulicos

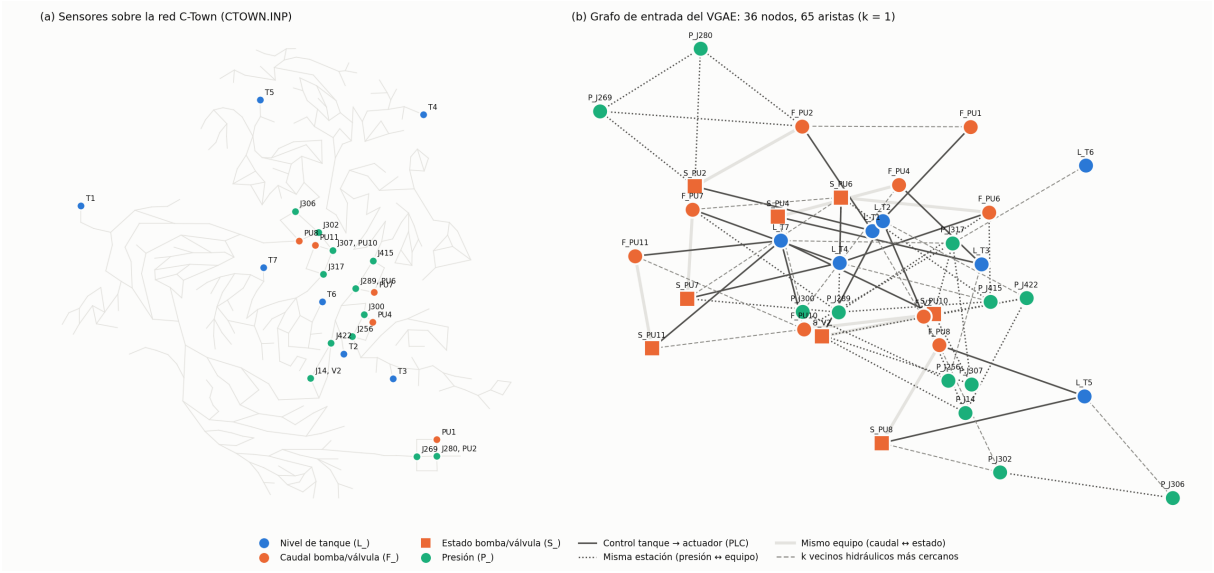


Figura 1: (a) Ubicación de los sensores en la red C-Town. (b) Grafo de entrada del VGAE con los cuatro tipos de arista.

más cercanos de otro dispositivo. Con el valor seleccionado $k = 1$ el grafo tiene 65 aristas: 8 de dispositivo, 24 de estación, 17 de control y 16 hidráulicas (Figura 1). Como varios sensores comparten ubicación, el paso (iv) presenta empates de distancia; la adyacencia usada en el entrenamiento se guarda con el modelo y todos los experimentos posteriores usan exactamente ese grafo.

4.2 Variational Graph Autoencoder para atributos de nodo

Usamos la convolución de grafos de Kipf y Welling [14], $\mathbf{H}^{(l+1)} = \sigma(\hat{\mathbf{A}}\mathbf{H}^{(l)}\mathbf{W}^{(l)})$ con $\hat{\mathbf{A}} = \tilde{\mathbf{D}}^{-1/2}(\mathbf{A}+\mathbf{I})\tilde{\mathbf{D}}^{-1/2}$. El VGAE original [13], extensión a grafos del autoencoder variacional [12], codifica cada nodo en una gaussiana latente y reconstruye solo la estructura. Como aquí el grafo es fijo y lo que cambia en el tiempo son los atributos, introducimos tres modificaciones: (a) un decoder de atributos, también GCN, que reconstruye la ventana de cada sensor; (b) *embeddings* aprendidos por nodo $\mathbf{e}_i \in \mathbb{R}^{d_e}$, que rompen la invariancia a permutaciones de la GCN y permiten distinguir, por ejemplo, una presión de un nivel de tanque; y (c) el decoder de producto interno original se conserva con peso pequeño como regularizador topológico. La arquitectura (Figura 2) es:

$$\mathbf{H} = \mathrm{ReLU}(\hat{\mathbf{A}}\,[\mathbf{X} \,\|\, \mathbf{E}]\,\mathbf{W}_1), \tag{1}$$

$$\boldsymbol{\mu} = \hat{\mathbf{A}}\,\mathbf{H}\mathbf{W}_\mu, \qquad \log \boldsymbol{\sigma}^2 = \hat{\mathbf{A}}\,\mathbf{H}\mathbf{W}_\sigma, \tag{2}$$

$$\mathbf{Z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (\mathbf{Z} = \boldsymbol{\mu} \text{ en inferencia}), \tag{3}$$

$$\hat{\mathbf{X}} = \mathrm{ReLU}(\hat{\mathbf{A}}\,[\mathbf{Z} \,\|\, \mathbf{E}]\,\mathbf{W}_d)\mathbf{W}_o, \qquad \hat{A}_{ij} = \sigma(\mathbf{z}_i^\top \mathbf{z}_j). \tag{4}$$

Con la configuración seleccionada el modelo tiene 20 364 parámetros. La pérdida es el negativo de una ELBO ponderada:

$$\mathcal{L} = \frac{1}{NW}\|\mathbf{X} - \hat{\mathbf{X}}\|_F^2 + \alpha\,\mathrm{BCE}_w(\mathbf{A}, \sigma(\mathbf{Z}\mathbf{Z}^\top)) + \frac{\beta}{N}\sum_{i=1}^{N}\mathrm{KL}\left(q(\mathbf{z}_i)\,\|\,\mathcal{N}(\mathbf{0},\mathbf{I})\right), \tag{5}$$

donde la entropía cruzada se pondera para compensar la dispersión del grafo. Como el decoder es una GCN, la reconstrucción de un sensor depende del estado latente de sus vecinos: una lectura falsificada que no concuerda con su entorno produce un error localizado en ese nodo,

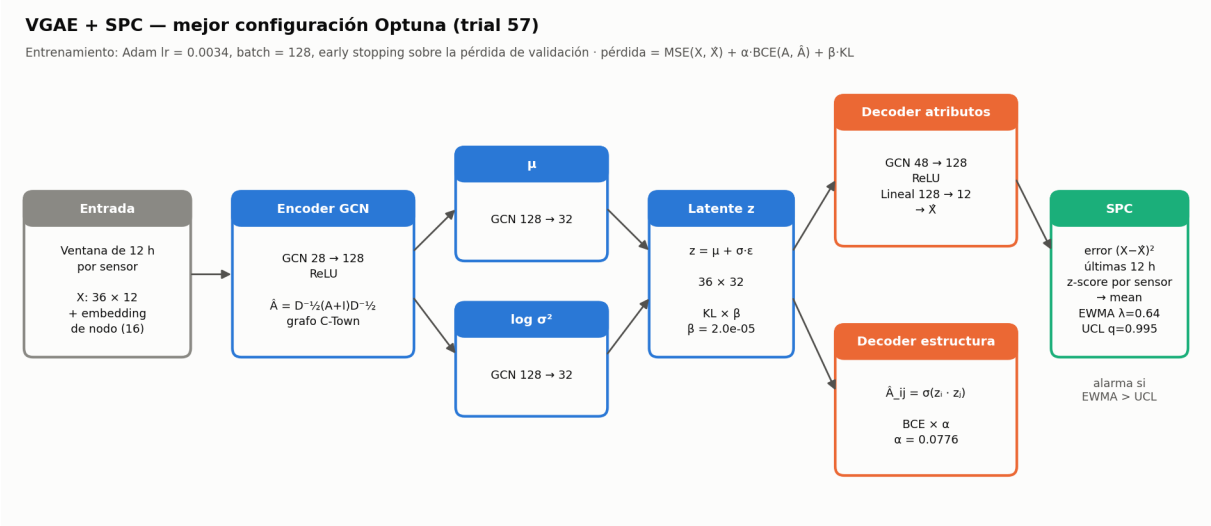


Figura 2: Arquitectura VGAE + SPC con la configuración seleccionada por Optuna. El bloque SPC muestra la carta EWMA de la búsqueda ($L = 12$, $\lambda = 0.64$, $q = 0.995$); en la comparación de cartas sus parámetros se reajustan (Sección 5).

y una lectura reproducida (*replay*) que sí parece normal deja huella en los nodos vecinos cuyo comportamiento real sí cambió.

4.3 Monitoreo con control estadístico de procesos

Las cartas se calibran en *Fase I* (20 % final de `dataset03`, operación normal no usada para ajustar pesos) y se aplican en *Fase II*. Siguiendo el MSPC basado en PCA, se vigilan dos aspectos complementarios del VGAE: el residuo, que detecta la pérdida de coherencia física entre sensores (p. ej. un nivel de tanque falsificado que no concuerda con los caudales de sus bombas), y el espacio latente, que detecta una operación físicamente coherente pero en un régimen inusual, caso típico de la manipulación de actuadores o consignas.

Estadístico de residuo por sensor. Sea $\mathbf{R}_t = (\mathbf{X}_t - \hat{\mathbf{X}}_t)^{\odot 2}$. Para cada sensor se promedia el error de las últimas L horas, se toma logaritmo y se estandariza con media m_i y desviación s_i de Fase I:

$$z_{t,i} = \frac{\log\left(\frac{1}{L}\sum_{\ell=W-L+1}^{W} R_{t,i\ell} + 10^{-6}\right) - m_i}{s_i}. \tag{6}$$

El logaritmo reduce la asimetría del error cuadrático y la estandarización hace comparables sensores con niveles de error muy distintos, de modo que un ataque localizado no se diluye entre los 36 nodos. Los $z_{t,i}$ se agregan en un escalar s_t mediante la media, el máximo o la media de los tres mayores.

Carta EWMA sobre el residuo. $C_t = \lambda s_t + (1-\lambda)C_{t-1}$, con $C_0 = \bar{s}_{\text{F.I}}$ y $\lambda \in (0, 1]$. Los ataques de BATADAL, en particular los que ocultan la manipulación, producen desviaciones moderadas que se sostienen durante horas o días, para las que las cartas con memoria son más sensibles [18]. La carta de Shewhart es el caso particular $\lambda = 1$; como ese valor se incluye en la búsqueda de λ, no se trata como una carta aparte, pero se reporta como referencia sin memoria. No se incluye la CUSUM, cuyo desempeño ante desplazamientos pequeños y sostenidos es prácticamente equivalente al de la EWMA [17] y que añadiría otro parámetro que ajustar con los mismos siete ataques.

Carta T^2 sobre el espacio latente. Con el *embedding* del grafo $\bar{\boldsymbol{\mu}}_t = \frac{1}{N}\sum_i \boldsymbol{\mu}_{t,i}$ se calcula $T_t^2 = (\bar{\boldsymbol{\mu}}_t - \mathbf{m})^\top \mathbf{S}^+ (\bar{\boldsymbol{\mu}}_t - \mathbf{m})$ con media y covarianza de Fase I.

Carta SPE. Como referencia clásica del MSPC se incluye el estadístico Q sin estandarizar, $Q_t = \sum_i \frac{1}{L}\sum_\ell R_{t,i\ell}$, con el límite de Box [5, 19] UCL $= g\,\chi^2_h(q)$, $g = v/2m$, $h = 2m^2/v$, donde m y v son la media y la varianza de Q en Fase I.

Límites y regla combinada. Las ventanas consecutivas comparten $W-1$ horas, por lo que las series monitoreadas están fuertemente autocorrelacionadas y los límites teóricos para observaciones independientes producirían un exceso de falsas alarmas. Para la EWMA y el T^2 el límite es el cuantil empírico q de la carta en Fase I, UCL $= Q_q(\{C_t\}_{\text{F.I}})$, lo que fija una tasa nominal de falsas alarmas $1-q$. Siguiendo la práctica del MSPC de vigilar residuo y subespacio a la vez, el detector propuesto es la regla EWMA $\vee$ T^2, que alarma si cualquiera de las dos cartas supera su límite.

5 Diseño experimental

Métrica. Se usa la métrica oficial de BATADAL [23], $S = \gamma\, S_{\text{TTD}} + (1-\gamma)\, S_{\text{CM}}$ con $\gamma = 0.5$, donde $S_{\text{TTD}} = 1 - \frac{1}{n_A}\sum_a \text{TTD}_a/\Delta t_a$ (TTD: horas desde el inicio del ataque hasta la primera alarma dentro de su ventana; Δt_a si no se detecta) y $S_{\text{CM}} = (\text{TPR} + \text{TNR})/2$ a nivel horario. Se reportan además precisión, F_1 y número de ataques detectados.

Entrenamiento. Adam sobre las ventanas del 80 % inicial de `dataset03`, hasta 300 épocas con *early stopping* (paciencia 25) sobre el 20 % final, restaurando los mejores pesos. En la práctica el criterio de parada casi nunca se activó: la mediana de épocas en los ensayos de la búsqueda fue 300 y el modelo final alcanzó su mejor pérdida de validación en la época 297.

Selección de hiperparámetros. Los hiperparámetros del VGAE y de la carta EWMA se seleccionan conjuntamente con Optuna [2] maximizando S en `dataset04` (Tabla 3). El estudio principal usa TPE multivariante [4] con 100 ensayos (10 aleatorios iniciales). Como controles se ejecutan: (i) una búsqueda aleatoria de 50 ensayos con el mismo espacio, comparada con TPE mediante la prueba U de Mann–Whitney unilateral; (ii) la importancia de hiperparámetros por fANOVA [10]; y (iii) el reentrenamiento de la mejor configuración TPE, la mejor aleatoria y la configuración por defecto con 10 semillas nuevas (100–109), contrastadas con la prueba de Wilcoxon pareada por semilla. El conjunto de prueba se evalúa por primera vez en la etapa (iii).

Comparación de cartas. Con el VGAE final, los parámetros de cada carta se reajustan por búsqueda en rejilla sobre `dataset04`, pues los pesos finales del modelo difieren de los del ensayo de Optuna: para la EWMA, $L \in \{1,3,6,12\}$, agregación $\in$ {mean, max, top3}, $\lambda \in \{0.05, 0.1, 0.2, 0.5, 1\}$ y $q \in \{0.99, 0.995, 0.999\}$; para el T^2, q; y para SPE, $L \in \{1,3,6,12,24\}$ y q. Se reportan además dos referencias: la mejor configuración de la rejilla con $\lambda = 1$ (carta de Shewhart) y la EWMA con los parámetros de Optuna. Cada configuración se aplica sin cambios al conjunto de prueba.

Variante temporal. Se evalúa una variante que sustituye la capa lineal de entrada y salida por bloques convolucionales 1D dilatados ($d \in \{1,2,4\}$, campo receptivo de 15 h) con codificación circular de la hora del día, en la línea de STGCN [24] y TCN [3] (71 185 parámetros). Se compara con el modelo base en un diseño pareado: mismos hiperparámetros (los de Optuna), mismo grafo, mismo presupuesto de entrenamiento (300 épocas, paciencia 25), mismas 10 semillas (100–109) y la carta EWMA con los parámetros de Optuna; la única diferencia es el bloque temporal. Como

Tabla 3: Espacio de búsqueda, configuración por defecto y configuración seleccionada por TPE.

Grupo	Hiperparámetro	Espacio	Defecto	TPE
Entrada y grafo	Ventana W (h)	$\{12, 24, 48\}$	24	12
	Vecinos hidráulicos k	$\{1, \ldots, 5\}$	3	1
Arquitectura	Capa oculta h	$\{32, 64, 128\}$	64	128
	Dimensión latente d_z	$\{4, 8, 16, 32\}$	16	32
	Embedding de nodo d_e	$\{4, 8, 16\}$	8	16
Entrenamiento	Tasa de aprendizaje	$[10^{-4}, 5 \cdot 10^{-3}]$ (log)	10^{-3}	$3.36 \cdot 10^{-3}$
	Tamaño de lote	$\{128, 256, 512\}$	$64^{\dagger}$	128
	Peso estructura α	$[10^{-3}, 1]$ (log)	0.1	0.078
	Peso KL β	$[10^{-5}, 10^{-1}]$ (log)	10^{-3}	$2.0 \cdot 10^{-5}$
Carta EWMA	Horizonte L (h)	$\{1, 3, 6, 12\}$	6	12
	Agregación	{mean, max, top3}	mean	mean
	λ	$[0.05, 1]$ (log)	0.2	0.645
	Cuantil q	$\{0.99, 0.995, 0.999\}$	0.99	0.995

†La configuración por defecto se fijó antes de la búsqueda; el espacio de tamaños de lote se definió después para aprovechar la GPU y no incluye el valor 64.

Tabla 4: Robustez frente a la semilla: media ± desviación sobre 10 semillas (100–109), carta EWMA con los parámetros de cada configuración.

	`dataset04`		Prueba			
Configuración	S	F_1	S	TPR	TNR	F_1
TPE (mejor)	$\mathbf{0.852 \pm 0.014}$	$\mathbf{0.676 \pm 0.006}$	$\mathbf{0.750 \pm 0.017}$	$\mathbf{0.426 \pm 0.026}$	$\mathbf{0.976 \pm 0.005}$	$\mathbf{0.557 \pm 0.020}$
Aleatoria (mejor)	0.704 ± 0.034	0.578 ± 0.017	0.496 ± 0.062	0.197 ± 0.092	0.972 ± 0.004	0.292 ± 0.117
Por defecto	0.722 ± 0.052	0.592 ± 0.014	0.529 ± 0.035	0.185 ± 0.022	0.968 ± 0.002	0.281 ± 0.028

los hiperparámetros se eligieron para el modelo base, la comparación es conservadora respecto de la variante.

6 Resultados

6.1 Selección de hiperparámetros

La búsqueda TPE alcanzó su mejor valor, $S = 0.879$ en `dataset04`, en el ensayo 57, frente a 0.751 de la mejor configuración aleatoria. La mediana de S por ensayo fue 0.802 para TPE (ensayos guiados) y 0.586 para la búsqueda aleatoria (Mann–Whitney, $U = 4294$, $p = 3.1 \cdot 10^{-19}$). Según fANOVA, en el estudio TPE la agregación del estadístico explica el 45.5 % de la varianza de S, seguida de la ventana W (17.4 %) y la dimensión latente (15.0 %); el resto de hiperparámetros explica menos del 4 % cada uno. En la búsqueda aleatoria domina λ (56.7 %), lo que indica que, fuera de la región favorable, la memoria de la carta es el factor que más condiciona el desempeño.

La Tabla 4 muestra que la ventaja se mantiene al reentrenar con semillas nuevas y se transfiere al conjunto de prueba. La configuración TPE supera a la configuración por defecto y a la mejor aleatoria (Wilcoxon unilateral, $p = 0.00098$, el mínimo alcanzable con 10 pares), con una dispersión entre semillas menor.

6.2 Comparación de cartas de control

El modelo final se entrenó con la configuración TPE y la semilla 0. Con la EWMA de Optuna obtiene $S = 0.722$ en prueba, ligeramente por debajo del rango observado con las 10 semillas de la Tabla 4 (0.728–0.780). La Tabla 5 resume el desempeño de cada carta y la Figura 4 muestra su evolución sobre el conjunto de prueba.

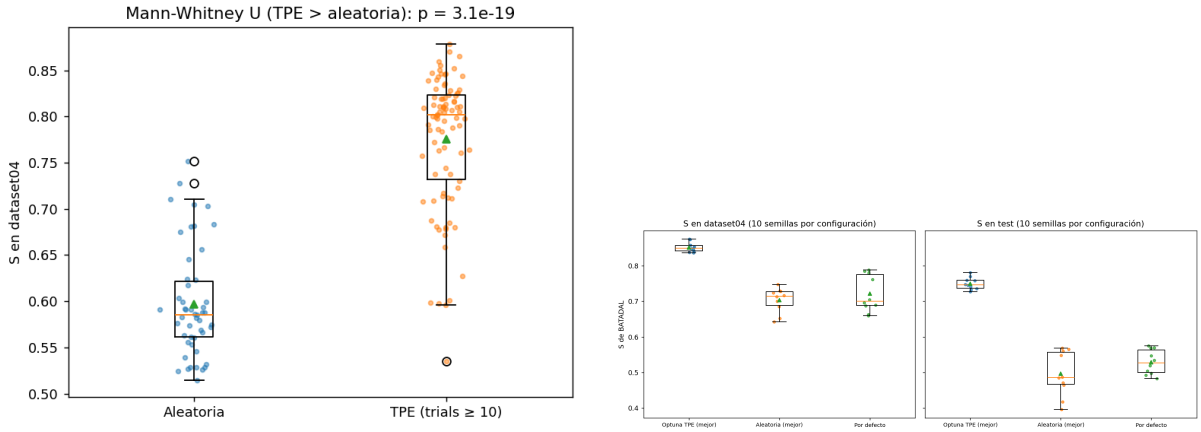


Figura 3: Izquierda: distribución de S en `dataset04` por ensayo, TPE frente a búsqueda aleatoria. Derecha: S por semilla para las tres configuraciones.

Tabla 5: Desempeño de las cartas con el VGAE final. Parámetros elegidos en `dataset04` y aplicados sin cambios a prueba. Det.: ataques detectados de 7. EWMA λ=1: mejor configuración de la rejilla sin memoria (carta de Shewhart).

Conjunto	Carta	Parámetros	S	S_{TTD}	S_{CM}	TPR	TNR	Prec.	F_1	Det.
`dataset04`	EWMA	L=3, mean, λ=0.1	0.903	0.942	0.863	0.833	0.893	0.511	0.633	7
	EWMA λ=1	L=12, max	0.887	**0.970**	0.805	**0.854**	0.756	0.318	0.464	7
	EWMA (Optuna)	L=12, λ=0.645	0.837	0.886	0.788	0.604	0.973	0.748	**0.668**	7
	T^2	—	0.729	0.705	0.754	0.533	0.976	0.744	0.621	7
	SPE	L=6	0.623	0.545	0.701	0.411	**0.991**	**0.852**	0.554	6
	EWMA $\vee$ T^2	—	**0.908**	0.952	**0.865**	0.841	0.889	0.503	0.630	7
Prueba	EWMA	L=3, mean, λ=0.1	0.765	0.776	0.754	0.575	0.934	0.678	0.622	7
	EWMA λ=1	L=12, max	**0.855**	**0.960**	0.749	**0.727**	0.772	0.435	0.545	7
	EWMA (Optuna)	L=12, λ=0.645	0.722	0.765	0.679	0.378	0.979	**0.815**	0.517	7
	T^2	—	0.678	0.744	0.613	0.243	0.983	0.773	0.370	7
	SPE	L=6	0.356	0.192	0.520	0.044	**0.996**	0.720	0.083	2
	EWMA $\vee$ T^2	—	0.819	0.848	**0.790**	0.651	0.929	0.688	**0.669**	7

Cuantil $q = 0.99$ en todas las cartas salvo EWMA (Optuna), con $q = 0.995$.

Cuatro resultados destacan:

1. **El estadístico estandarizado por sensor es decisivo.** Las cartas construidas sobre $z_{t,i}$ detectan los 7 ataques en ambos conjuntos, mientras que la carta SPE, que suma el error crudo, detecta 6 de 7 en `dataset04` y solo 2 de 7 en prueba ($S = 0.356$): unos pocos sensores difíciles de reconstruir dominan Q_t y enmascaran los ataques localizados.

2. **Residuo y latente son complementarios.** El T^2 es la carta más conservadora entre las que detectan los 7 ataques (TNR 0.983), pero aporta detecciones tempranas donde el residuo tarda: en el ataque 12 la EWMA alarma a las 48 h y el T^2 a las 7 h. La regla EWMA $\vee$ T^2 mejora a la EWMA en prueba de $S = 0.765$ a 0.819 y obtiene el mejor S_{CM} y F_1 de todas las cartas.

3. **La memoria aporta en `dataset04`, pero la ventaja no se mantiene en S.** En `dataset04` la EWMA con $\lambda = 0.1$ supera a la versión sin memoria (0.903 frente a 0.887); en prueba el orden se invierte (0.765 frente a 0.855).

4. **La carta sin memoria obtiene el mayor S en prueba, pero con muchas falsas alarmas.** Su TNR es 0.772: alarma en el 23 % de las horas normales, frente al 1 % nominal (Sección 7).

Tabla 6: Tiempo hasta la detección (h) por ataque en el conjunto de prueba. "—": no detectado.

Ataque	Duración	EWMA	EWMA λ=1	EWMA (Optuna)	T^2	SPE	EWMA $\vee$ T^2
8	70	7	2	5	38	—	7
9	65	11	4	6	7	—	7
10	31	1	1	3	5	—	1
11	31	4	1	4	7	8	4
12	100	48	0	47	7	—	7
13	80	18	2	23	23	—	18
14	30	13	3	15	12	12	12

6.3 Tiempo hasta la detección por ataque

La Tabla 6 detalla los tiempos de detección. Los ataques 10 y 11 (activación de PU3, sin ocultamiento) se detectan en 1–4 h con todas las cartas basadas en z. Los ataques con *replay* (8, 12 y 13) son los más lentos para la EWMA: en el 12 tarda casi la mitad del ataque. En ese caso el T^2 adelanta la detección de la regla combinada de 48 a 7 h.

6.4 Diagnóstico: qué sensores explican la alarma

Como el estadístico (6) está definido por sensor, cada alarma puede atribuirse a los nodos que más contribuyen a ella. La Figura 5 muestra el z medio de cada sensor durante cada ataque de prueba. Para interpretarla hay que tener en cuenta una línea base: en las horas normales de prueba, los sensores del subsistema T1–PU1/PU2 (S_PU2, F_PU2, F_PU1, L_T1) tienen un z medio de 1.4–1.9, frente a una mediana de 0.02 en el resto de sensores (Sección 7). Por eso, valores de ese orden en esos sensores no constituyen evidencia de ataque.

- **Ataques sin ocultamiento o con ocultamiento parcial** (8, 9, 14): los sensores con mayor z coinciden con el componente atacado o con su lazo de control ($P_J256 = 8.4$, $F_PU4 = 6.8$, $S_PU4 = 6.6$ y $L_T3 = 3.7$ en el ataque 8; $F_V2 = 3.4$ y $L_T2 = 2.6$ en el 9; $F_PU7 = 3.4$ y $L_T4 = 2.7$ en el 14).
- **Componente sin sensores** (10, 11): PU3 no forma parte del modelo, pero su activación altera el tanque T1 y la estación PU1/PU2 ($L_T1 = 7.9$ y 9.0, $F_PU1 = 5.4$ y 8.1), muy por encima de la línea base de ese subsistema. La detección se apoya íntegramente en la propagación por el grafo.
- ***Replay*** (12, 13): los sensores reproducidos tienen z bajo o negativo (p. ej. $F_V2 = -1.9$ y $P_J422 = -2.7$ en el ataque 12; 0.4–0.9 en los sensores de PU10/PU11 en el 13), porque muestran datos normales. En el ataque 13 la alarma proviene de efectos físicos que el atacante no ocultó ($L_T6 = 2.9$, $P_J302 = 2.6$). En el ataque 12 los z más altos (2.2–2.6 en PU1/PU2) no superan la línea base; descontada esta, el sensor con mayor exceso es L_T2 (+1.6), uno de los reproducidos, de modo que el diagnóstico de este ataque es débil.

El diagnóstico debe interpretarse, por tanto, como "dónde se rompe la coherencia física respecto a la operación normal reciente" y no necesariamente como "qué sensor fue atacado": en los ataques con *replay*, los sensores del componente atacado son precisamente los que parecen más normales.

6.5 Variante con convolución temporal

La Tabla 7 y la Figura 6 resumen la comparación pareada con 10 semillas. La variante temporal obtiene una pérdida de validación menor (0.149 frente a 0.161) y converge antes: el *early stopping* la detiene en una mediana de 170 épocas (rango 100–300), mientras que el modelo base agota



Figura 4: Cartas de control sobre el conjunto de prueba con el VGAE final. Sombreado: ataques reales; línea discontinua: límite de control; puntos: alarmas. Escala logarítmica simétrica en T^2 y SPE.

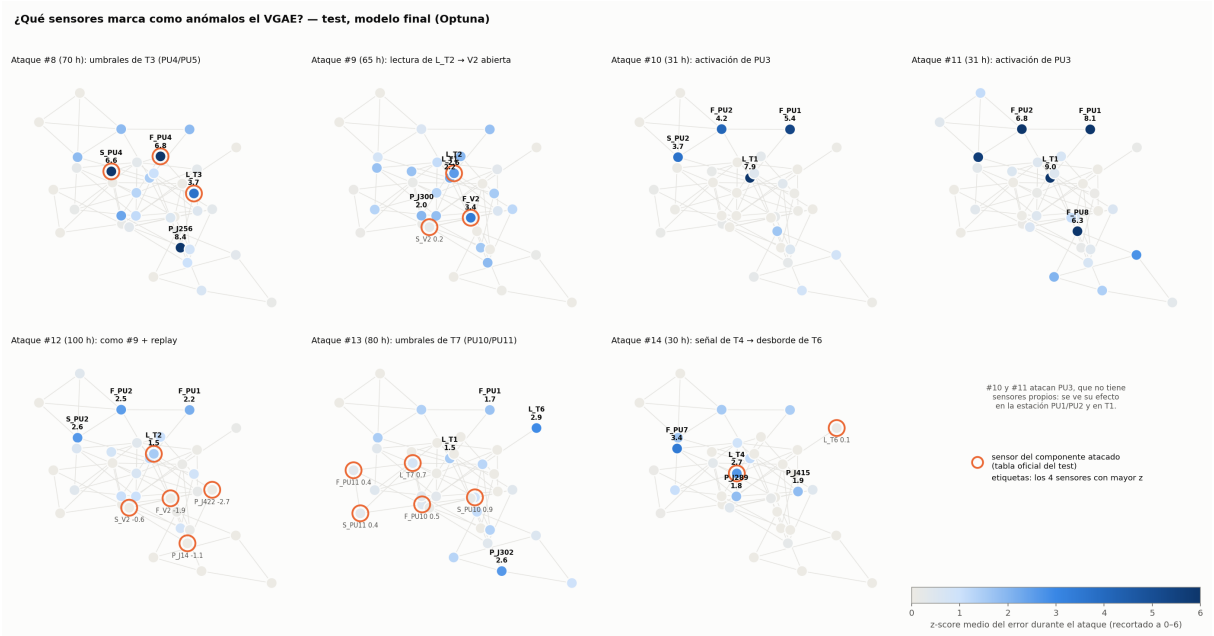


Figura 5: z medio del error de reconstrucción por sensor durante cada ataque de prueba, con el horizonte $L = 12$ h de la configuración Optuna. Círculos: sensores del componente atacado según la documentación oficial; etiquetas: los cuatro sensores con mayor z.

Tabla 7: Comparación pareada del VGAE base y la variante con convolución temporal: media ± desviación sobre 10 semillas (100–109), 300 épocas con paciencia 25, carta EWMA con los parámetros de Optuna.

		`dataset04`	Prueba			
Modelo	Pérdida val.	S	S	TPR	TNR	F_1
VGAE base	0.161 ± 0.001	0.855 ± 0.018	0.741 ± 0.016	0.420 ± 0.026	0.977 ± 0.004	0.553 ± 0.022
+ conv. temporal	0.149 ± 0.005	0.866 ± 0.017	0.758 ± 0.025	0.465 ± 0.051	0.973 ± 0.006	0.589 ± 0.040
Diferencia (gana)	—	+0.011 (6/10)	+0.016 (7/10)			
Wilcoxon bilateral	—	$p = 0.19$	$p = 0.13$			

las 300 en todas las semillas. En detección, la variante mejora la S media en prueba en +0.016 y gana en 7 de 10 semillas, pero la diferencia no es significativa (Wilcoxon bilateral, $p = 0.13$); en `dataset04` la mejora es de +0.011 (6 de 10, $p = 0.19$). Gran parte de la diferencia media en prueba se debe a una sola semilla (109, +0.092); la mediana de las diferencias es +0.014. La mejora proviene sobre todo de la sensibilidad (TPR 0.465 frente a 0.420), con una TNR prácticamente igual.

Una comparación preliminar con solo 40 épocas había mostrado una ventaja mucho mayor (+0.086 en prueba con 2 semillas). Con el presupuesto completo la ventaja se reduce a una quinta parte, lo que indica que procedía sobre todo de la convergencia más rápida de la variante y no de una mejor capacidad de detección. El modelo base de esta comparación coincide en configuración con la etapa de semillas de la Tabla 4 (0.741 ± 0.016 frente a 0.750 ± 0.017 en prueba); la pequeña diferencia es compatible con la variabilidad entre semillas y con haber entrenado en CPU en lugar de GPU.

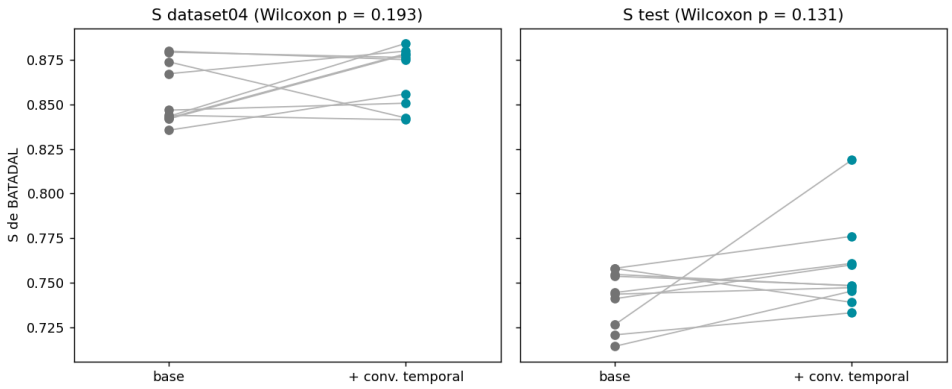


Figura 6: S por semilla del VGAE base y de la variante con convolución temporal; cada línea une los dos modelos entrenados con la misma semilla.

7 Discusión

La métrica S premia la densidad de alarmas. El término S_{TTD} solo mide la primera alarma dentro de cada ataque y no penaliza las alarmas previas. Taormina et al. [23] ya señalan que S está sesgada hacia la detección: un detector que siempre alarma obtiene $S = 0.75$. En nuestro caso, con la tasa de falsas alarmas de la carta sin memoria en prueba ($1 - \mathrm{TNR} = 0.228$), una alarma cae en promedio cada ≈ 4.4 h aun sin información sobre el ataque, lo que es del orden de sus TTD (0–4 h). Por ello su $S_{\mathrm{TTD}} = 0.960$ no debe leerse como evidencia de mayor sensibilidad. La regla EWMA $\vee$ T^2 ofrece un compromiso más útil para la operación: TNR de 0.929, precisión de 0.688 y el mejor F_1. Recomendamos reportar siempre TNR, precisión y F_1 junto a S.

La tasa nominal de falsas alarmas no se conserva. Los límites se fijan en el cuantil $q = 0.99$ de Fase I, pero las tasas observadas son del 10.7 % (`dataset04`) y 6.6 % (prueba) para la EWMA, del 7.1 % para la regla combinada en prueba y del 22.8 % para la carta sin memoria. Identificamos cuatro causas:

1. **Recuperación tras los ataques.** Las horas posteriores a un ataque cuentan como normales aunque el sistema aún se esté recuperando. En prueba, el 43 % de las falsas alarmas de la EWMA cae en las 24 h siguientes al final de un ataque, un intervalo que contiene solo el 10 % de las horas normales.

2. **Deriva localizada en T1–PU1/PU2.** Los sensores de este subsistema tienen un z medio de 1.1–1.6 ($L = 3$) en las horas normales de `dataset04` y de prueba, mientras que la mediana del resto es ≈ 0. No se trata de un cambio general de régimen: Taormina et al. [23] indican que los patrones de demanda son regulares y consistentes entre los tres conjuntos, y el resto de sensores se mantiene en su nivel de Fase I.

3. **Doble uso de la Fase I.** El mismo tramo sirve para el *early stopping* y para calibrar los límites. El modelo se elige para reconstruir bien esos datos, lo que estrecha los límites respecto de datos normales nuevos.

4. **Regla combinada sin recalibrar.** Cada carta usa su propio $q = 0.99$, por lo que la tasa nominal de la unión es mayor que la de cada carta.

Además, la Figura 4 muestra un evento sin ataque etiquetado (7–8 de marzo de 2017) que T^2, SPE y EWMA señalan con fuerza: la bomba PU6 se activa durante 2 h, un régimen que ocupa solo 16 de las 8 761 horas de `dataset03`. Es una operación legítima pero poco frecuente, que el detector, entrenado con datos normales, no puede distinguir de un ataque.

Tabla 8: Comparación con los participantes de BATADAL en el conjunto de prueba (Tabla 4 de Taormina et al. [23]). S_{CM} corresponde a S_{CLF} en la notación original.

Método	Det.	S	S_{TTD}	S_{CM}	TPR	TNR
Housh y Ohar	7	0.970	0.965	0.975	0.953	0.997
Abokifa et al.	7	0.949	0.958	0.940	0.921	0.959
Giacomoni et al.	7	0.927	0.936	0.917	0.838	0.997
Brentan et al.	6	0.894	0.857	0.931	0.889	0.973
VGAE + SPC (EWMA $\vee$ T^2)	7	**0.819**	0.848	0.790	0.651	0.929
Chandy et al.	7	0.802	0.835	0.768	0.857	0.678
Pasha et al.	7	0.773	0.885	0.660	0.329	0.992
Aghashahi et al.	3	0.534	0.429	0.640	0.396	0.884

La selección en `dataset04` y su transferencia. `dataset04` contiene solo 7 ataques, y el orden entre la EWMA y la carta sin memoria se invierte entre `dataset04` y prueba. Parte de la diferencia se explica por las tasas de falsas alarmas y el sesgo de S descrito arriba. Por ello fijamos el detector propuesto (EWMA $\vee$ T^2) por argumentos de diseño —la lógica residuo/latente del MSPC— y no por su S en prueba; los datos de validación se usan solo para ajustar sus parámetros.

Comparación con BATADAL. La Tabla 8 sitúa el detector propuesto frente a los participantes de la competición, evaluados sobre el mismo conjunto de prueba. Con $S = 0.819$ quedaría en la quinta posición, por debajo de los enfoques que combinan detección estadística con conocimiento del sistema. La comparación debe tomarse con cautela por dos diferencias de protocolo que favorecen a nuestro método: los participantes disponían de etiquetas parciales de `dataset04`, mientras que nosotros seleccionamos hiperparámetros con las ventanas completas reconstruidas tras la competición, y diseñamos el método conociendo ya los resultados de la competición. En sentido contrario, nuestro detector no usa el modelo hidráulico en línea ni datos de prueba sin etiquetar.

Limitaciones. (i) Los datos son simulados. (ii) La comparación de cartas se hizo sobre un único modelo final; la variabilidad entre semillas de la EWMA de Optuna es del orden de ± 0.02 en S (Tabla 4), y diferencias entre cartas de ese orden no deben interpretarse. (iii) Las ventanas consecutivas se solapan, por lo que los límites empíricos se basan en una muestra efectiva mucho menor que las 1 753 horas de Fase I. (iv) El entrenamiento no llegó a converger dentro del presupuesto de 300 épocas (mejor época 297), de modo que el modelo probablemente mejoraría con más épocas.

8 Conclusiones

Hemos presentado un detector de ciberataques para redes de distribución de agua que combina un VGAE sobre un grafo de sensores derivado de la física y del control de la red con cartas de control estadístico de procesos. El modelo se entrena solo con operación normal y produce alarmas interpretables a nivel de sensor. Con hiperparámetros seleccionados por TPE, cuya ventaja sobre la búsqueda aleatoria y la configuración por defecto es estadísticamente significativa y estable frente a la semilla, la regla EWMA $\vee$ T^2 detecta los 7 ataques de prueba de BATADAL con $S = 0.819$ y $F_1 = 0.669$. Tres hallazgos tienen alcance general: la estandarización del residuo por sensor es imprescindible para detectar ataques localizados; vigilar a la vez el residuo y el espacio latente aporta detecciones que ninguna carta logra por separado; y la métrica de BATADAL puede favorecer detectores con alta densidad de alarmas, por lo que debe acompañarse de TNR y precisión. Modelar explícitamente el orden temporal con convoluciones dilatadas acelera la

convergencia, pero con el presupuesto completo no aporta una mejora significativa en la detección. Como trabajo futuro se plantea separar la validación del *early stopping* de la Fase I, recalibrar los límites de la regla combinada, estudiar la deriva del subsistema T1–PU1/PU2 y evaluar el método en datos reales o en otros bancos de prueba como SWaT.

Referencias

[1] Abokifa, A. A., Haddad, K., Lo, C. y Biswas, P. (2019). Real-time identification of cyber-physical attacks on water distribution systems via machine learning–based anomaly detection techniques. *Journal of Water Resources Planning and Management*, 145(1).

[2] Akiba, T., Sano, S., Yanase, T., Ohta, T. y Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *KDD*.

[3] Bai, S., Kolter, J. Z. y Koltun, V. (2018). An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv:1803.01271*.

[4] Bergstra, J., Bardenet, R., Bengio, Y. y Kégl, B. (2011). Algorithms for hyper-parameter optimization. *NeurIPS*.

[5] Box, G. E. P. (1954). Some theorems on quadratic forms applied in the study of analysis of variance problems. *Annals of Mathematical Statistics*, 25(2).

[6] Deng, A. y Hooi, B. (2021). Graph neural network-based anomaly detection in multivariate time series. *AAAI*.

[7] Goh, J., Adepu, S., Junejo, K. N. y Mathur, A. (2016). A dataset to support research in the design of secure water treatment systems. *CRITIS*.

[8] Housh, M. y Ohar, Z. (2018). Model-based approach for cyber-physical attack detection in water distribution systems. *Water Research*, 139.

[9] Hundman, K., Constantinou, V., Laporte, C., Colwell, I. y Soderstrom, T. (2018). Detecting spacecraft anomalies using LSTMs and nonparametric dynamic thresholding. *KDD*.

[10] Hutter, F., Hoos, H. y Leyton-Brown, K. (2014). An efficient approach for assessing hyper-parameter importance. *ICML*.

[11] Jackson, J. E. y Mudholkar, G. S. (1979). Control procedures for residuals associated with principal component analysis. *Technometrics*, 21(3).

[12] Kingma, D. P. y Welling, M. (2014). Auto-encoding variational Bayes. *ICLR*.

[13] Kipf, T. N. y Welling, M. (2016). Variational graph auto-encoders. *NeurIPS Workshop on Bayesian Deep Learning*.

[14] Kipf, T. N. y Welling, M. (2017). Semi-supervised classification with graph convolutional networks. *ICLR*.

[15] Kourti, T. y MacGregor, J. F. (1995). Process analysis, monitoring and diagnosis, using multivariate projection methods. *Chemometrics and Intelligent Laboratory Systems*, 28(1).

[16] Kravchik, M. y Shabtai, A. (2018). Detecting cyber attacks in industrial control systems using convolutional neural networks. *CPS-SPC Workshop*.

[17] Lucas, J. M. y Saccucci, M. S. (1990). Exponentially weighted moving average control schemes: properties and enhancements. *Technometrics*, 32(1).

[18] Montgomery, D. C. (2019). *Introduction to Statistical Quality Control* (8.ª ed.). Wiley.

[19] Nomikos, P. y MacGregor, J. F. (1995). Multivariate SPC charts for monitoring batch processes. *Technometrics*, 37(1).

[20] Page, E. S. (1954). Continuous inspection schemes. *Biometrika*, 41(1–2).

[21] Roberts, S. W. (1959). Control chart tests based on geometric moving averages. *Technometrics*, 1(3).

[22] Taormina, R. y Galelli, S. (2018). Deep-learning approach to the detection and localization of cyber-physical attacks on water distribution systems. *Journal of Water Resources Planning and Management*, 144(10).

[23] Taormina, R., Galelli, S., Tippenhauer, N. O. et al. (2018). Battle of the Attack Detection Algorithms: Disclosing cyber attacks on water distribution networks. *Journal of Water Resources Planning and Management*, 144(8).

[24] Yu, B., Yin, H. y Zhu, Z. (2018). Spatio-temporal graph convolutional networks: a deep learning framework for traffic forecasting. *IJCAI*.